

Atelier Préparation de Données Tabulaires

Contexte

Une entreprise exploite plusieurs bâtiments intelligents équipés de capteurs IoT. Chaque capteur collecte régulièrement des informations sur la température, l'humidité, la qualité de l'air, la consommation énergétique, le nombre de personnes présentes, le type de bâtiment, le mode de fonctionnement et l'état du système de climatisation.

Les données collectées sont destinées à alimenter ultérieurement un modèle de Machine Learning capable de prédire la consommation énergétique ou de détecter les situations anormales.

Cependant, les données brutes présentent volontairement différents problèmes : valeurs manquantes, doublons, valeurs aberrantes, types incorrects, valeurs incohérentes, variables catégorielles, catégories rares, déséquilibre des classes et échelles différentes entre variables.

L'objectif de l'atelier est donc de transformer le fichier brut en un jeu de données propre et prêt pour le Machine Learning.

Objectifs pédagogiques

À la fin de l'atelier, l'apprenant doit être capable de :

- 1) explorer un jeu de données tabulaire ;
- 2) identifier les différents types de variables ;
- 3) détecter les problèmes de qualité ;
- 4) analyser les valeurs manquantes ;
- 5) détecter et traiter les doublons ;
- 6) identifier les valeurs aberrantes ;
- 7) détecter les incohérences ;
- 8) analyser le déséquilibre des classes ;
- 9) choisir une stratégie d'encodage adaptée ;
- 10) appliquer différents encodages catégoriels ;
- 11) normaliser et standardiser les variables numériques ;
- 12) éviter la fuite de données ;
- 13) construire un pipeline de preprocessing avec Scikit-learn ;
- 14) produire un dataset final exploitable par un algorithme de Machine Learning.

Structure du projet

- 1) Structurer le projet comme suit :

```
atelier_prepa_donnees_tab/  
├── data/  
│   └── smart_building_raw.csv  
├── notebooks/  
│   └── atelier_prepa_donnees_tab.ipynb  
└── exports/  
    └── smart_building_cleaned.csv
```

- 1) Stocker le fichier fourni `smart_building_raw.csv` dans le sous-dossier `data`
- 2) Créer le notebook `atelier_prepa_donnees_tab.ipynb`
- 3) NB : le fichier `smart_building_cleaned.csv` sera créé à la fin de l'atelier

Partie 1 – Explorer les données

- 1) Charger les données CSV ;
- 2) Afficher les premières lignes du dataset ;
- 3) Afficher les dernières lignes du dataset ;
- 4) Combien d'observations contient le dataset ?
- 5) Combien de variables possède le dataset ?
- 6) Identifier les variables numériques ;
- 7) Identifier les variables catégorielles ;
- 8) Identifier les dates
- 9) Identifier les identifiants
- 10) Déterminer les statistiques : moyenne, médiane, minimum, maximum, écart-type et quartiles.
- 11) Y a-t-il des variables potentiellement problématiques ?
- 12) Pour les données incohérentes :
 - a) rechercher des valeurs telles que humidité < 0 ;
 - b) rechercher des valeurs telles que humidité > 100 ;
 - c) rechercher des valeurs telles que température extrêmement élevée ;
 - d) rechercher des valeurs telles que négative ;
 - e) rechercher des valeurs telles que consommation négative ;
 - f) Si une valeur est manifestement erronée et qu'on ne peut pas retrouver sa vraie valeur, la transformer en valeur manquante
 - g) rechercher des valeurs telles que catégories mal orthographiées.
 - h) normaliser les catégories textuelles en supprimant les espaces puis en uniformisant la casse
- 13) Pour les valeurs manquantes :
 - a) Calculer le nombre et le pourcentage de valeurs manquantes par colonne
 - b) Quelle variable possède le plus de valeurs manquantes ?
 - c) Quelle stratégie utiliser pour les valeurs manquantes ?
 - d) Peut-on supprimer toutes les lignes contenant des valeurs manquantes ?
 - e) Dans quels cas utiliser la moyenne ?
 - f) Quand préférer la médiane ?
 - g) Comment traiter une variable catégorielle ?
- 14) Pour les doublons
 - a) Identifier les
 - b) Afficher les
 - c) sont-ils réellement identiques ?
 - d) supprimer les doublons réellement identifiés.
 - e) Vérifier la suppression
- 15) Pour la température, l'humidité, le CO₂ et la consommation, identifier visuellement :
 - a) Les distributions (symétrique ou non)
 - b) La dispersion
 - c) Les valeurs extrêmes
 - d) les valeurs potentiellement aberrantes
- 16) Quelle stratégie utiliser pour les valeurs aberrantes ?
- 17) Afficher la fréquence des :
 - a) bâtiments ;
 - b) types de bâtiments ;
 - c) modes de climatisation ;
 - d) états du système ;
 - e) classes alerte.

- 18) Y a-t-il un déséquilibre des classes sur la variable « alerte » ?
- 19) Pour la corrélation sur les variables numériques :
- visualiser avec seaborn, la matrice de corrélation.
 - identifier les corrélations positives, négatives et les variables faiblement corrélées.

Partie 2 – Séparation X / y

- Définir la variable "**alerte**" comme la cible y
- Trouver des variables explicatives X pertinentes
- Afficher les cinq premières lignes de **x** ainsi que de **y**

Partie 3 – Découpage Train/Test

Diviser **x** en deux ensembles distincts : un pour l'entraînement (**train**) et un pour le test (**test**). Avec les conditions suivantes : 20% des données serviront au test ; garantir la reproductibilité du découpage ; conserver les mêmes proportions de classes dans l'ensemble de train et de test que dans les données d'origine.

Partie 4 – Encodage des variables catégorielles


Appliquer, en justifiant, l'encodage le plus adapté à chaque variable catégorielle

Partie 5 – Mise à l'échelle

- A l'aide de quelques variables, justifier la pertinence de la mise à l'échelle
- Appliquer et justifier une technique de mise à l'échelle
- Pourquoi ne doit-on pas calculer la moyenne et l'écart-type à partir du dataset complet ?

Partie 6 – Pipeline de preprocessing

Avec Scikit-learn, construire un pipeline de preprocessing semblable à :



Partie 7 : Exportation

Exporter le dataframe nettoyé dans **exports/smart_building_cleaned.csv**

Partie 8 : Bonus

Proposer et réaliser toute fonctionnalité pertinente et utile qu'on pourrait rajouter à l'atelier.

Livrable attendu

Chaque apprenant devra fournir le dossier `atelier_prepa_donnees_tab`

Modalités de livraison

Chaque apprenant pousse

- 1) le livrable, **d'abord vide**, sur un dépôt public de son compte Github personnel ;
- 2) met à jour le livrable **après chaque tâche accomplie** (sans attendre de terminer toute une partie), avec un message de commit explicite.